



Mata Kuliah

2025

EDA & Preprocessing

Informatika Medis

Data

Data

Data adalah kumpulan fakta, angka, simbol, atau informasi mentah yang belum diolah.

Dalam konteks analisis data, data bisa berbentuk:

- Numerik: angka (misalnya tinggi badan, umur)
- Kategorikal: label atau kategori (misalnya jenis kelamin, warna)
- Teks: data dalam bentuk kalimat atau paragraf
- Waktu/Temporal: data yang melibatkan waktu



Jenis-Jenis Data

1. Data Berdasarkan Sifatnya:

- Kualitatif (kategorikal):

Nominal: tanpa urutan (contoh: warna, gender)

Ordinal: ada urutan (contoh: rating, level pendidikan)

- Kuantitatif (numerik):

Diskrit: bilangan bulat (contoh: jumlah anak)

Kontinu: bilangan desimal (contoh: tinggi badan)

2. Data Berdasarkan Sumbernya:

Primary data: data dikumpulkan langsung oleh peneliti

Secondary data: data yang telah dikumpulkan pihak lain

3. Data Berdasarkan Waktu:

Cross-sectional: dikumpulkan pada satu titik waktu

Time-series: dikumpulkan sepanjang waktu

	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin	BMI	DiabetesPedigreeFunction	Age	Outcome
0	6	148	72	35	0	33.6	0.627	50	1
1	1	85	66	29	0	26.6	0.351	31	0
2	8	183	64	0	0	23.3	0.672	32	1
3	1	89	66	23	94	28.1	0.167	21	0
4	0	137	40	35	168	43.1	2.288	33	1



Mata Kuliah

2025

EDA & Preprocessing


Informatika Medis

Explanatory Data Analysis

EDA

EDA adalah proses awal dalam analisis data untuk memahami struktur, pola, anomali, dan hubungan antar variabel melalui statistik dan visualisasi.

	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin	BMI	DiabetesPedigreeFunction	Age	Outcome
0	6	148	72	35	0	33.6	0.627	50	1
1	1	85	66	29	0	26.6	0.351	31	0
2	8	183	64	0	0	23.3	0.672	32	1
3	1	89	66	23	94	28.1	0.167	21	0
4	0	137	40	35	168	43.1	2.288	33	1




Tujuan EDA

- Memahami distribusi data
- Mengidentifikasi outlier dan missing values
- Menemukan pola dan hubungan antar variabel
- Menentukan teknik preprocessing dan pemodelan

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 768 entries, 0 to 767
Data columns (total 9 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Pregnancies            768 non-null   int64
1   Glucose                768 non-null   int64
2   BloodPressure          768 non-null   int64
3   SkinThickness          768 non-null   int64
4   Insulin                768 non-null   int64
5   BMI                    768 non-null   float64
6   DiabetesPedigreeFunction 768 non-null   float64
7   Age                    768 non-null   int64
8   Outcome                768 non-null   int64
dtypes: float64(2), int64(7)
memory usage: 54.1 KB
```



Teknik-Teknik EDA

1. Statistik Deskriptif:

- Rata-rata, median, modus, standar deviasi, varians
- Min, max, kuartil

2. Visualisasi Data:

- Histogram: distribusi data numerik
- Boxplot: deteksi outlier dan spread data
- Scatter plot: korelasi antara dua variabel
- Bar chart: distribusi data kategorikal
- Heatmap: korelasi antar variabel

3. Deteksi Masalah:

- Missing values
- Outlier Data imbalance



Mata Kuliah

2025


EDA & Preprocessing

Informatika Medis


Preprocessing Data

Preprocessing Data

Data preprocessing adalah tahap pembersihan dan transformasi data mentah agar siap digunakan dalam pemodelan atau analisis lanjutan.



Langkah-langkah Umum Preprocessing



	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin	BMI	DiabetesPedigreeFunction	Age	Outcome
0	6	148	72	35	0	33.6	0.627	50	1
1	1	85	66	29	0	26.6	0.351	31	0
2	8	183	64	0	0	23.3	0.672	32	1
3	1	89	66	23	94	28.1	0.167	21	0
4	0	137	40	35	168	43.1	2.288	33	1



```

# According to BMI, some ranges were determined and categorical variables were assigned.
NewBMI = pd.Series(["Underweight", "Normal", "Overweight", "Obesity 1", "Obesity 2", "Obesity 3"], dtype = "category")

df["NewBMI"] = NewBMI

df.loc[df["BMI"] < 18.5, "NewBMI"] = NewBMI[0]

df.loc[(df["BMI"] > 18.5) & (df["BMI"] <= 24.9), "NewBMI"] = NewBMI[1]
df.loc[(df["BMI"] > 24.9) & (df["BMI"] <= 29.9), "NewBMI"] = NewBMI[2]
df.loc[(df["BMI"] > 29.9) & (df["BMI"] <= 34.9), "NewBMI"] = NewBMI[3]
df.loc[(df["BMI"] > 34.9) & (df["BMI"] <= 39.9), "NewBMI"] = NewBMI[4]
df.loc[df["BMI"] > 39.9, "NewBMI"] = NewBMI[5]

df.head()

```

	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin	BMI	DiabetesPedigreeFunction	Age	Outcome	NewBMI
0	6	148.00	72.00	35.00	169.50	33.60	0.63	50	1	Obesity 1
1	1	85.00	66.00	29.00	102.50	26.60	0.35	31	0	Overweight
2	8	183.00	64.00	32.00	169.50	23.30	0.67	32	1	Normal
3	1	89.00	66.00	23.00	94.00	28.10	0.17	21	0	Overweight
4	0	137.00	40.00	35.00	168.00	43.10	2.29	33	1	Obesity 3



```

df = pd.get_dummies(df, columns = ["NewBMI", "NewInsulinScore", "NewGlucose"], drop_first = True)

df.head()

```

	NewBMI_Obesity 1	NewBMI_Obesity 2	NewBMI_Obesity 3	NewBMI_Overweight	NewBMI_Underweight	NewInsulinScore_Normal	NewGlucose_
1	0	0	0	0	0	0	0
0	0	0	0	1	0	1	0
0	0	0	0	0	0	0	0
0	0	0	0	1	0	1	0
0	0	1	0	0	0	0	0



Terima Kasih